

Introducción a los K-vecinos más cercanos

Técnicas de clasificación y regresión.

1) **Clasificación**: Sea $\{(\underline{x}_1, y_1), \dots, (\underline{x}_n, y_n)\}$ una m.a. donde $\underline{x}_i \in \mathbb{R}^p$ y $y_i \in \{c_1, \dots, c_J\} = C$

Ahora sea \underline{x} una nueva observación cuya clase $Y \in C$ se desea predecir.

Primero se calculan las distancias de \underline{x} a $\underline{x}_1, \dots, \underline{x}_n$:

$$e_{\underline{x}, i} = \|\underline{x} - \underline{x}_i\|, \quad i=1, \dots, n.$$

Ahora se define

$$e_{\underline{x}, (1)} = \min_i e_{\underline{x}, i} \quad (\text{la menor distancia})$$
$$e_{\underline{x}, (2)} = \min_i e_{\underline{x}, i} \setminus e_{\underline{x}, (1)} \quad (\text{la segunda menor distancia})$$
$$\vdots$$
$$e_{\underline{x}, (n)} = \max_i e_{\underline{x}, i} \quad (\text{la mayor distancia})$$

Los K vecinos más cercanos a \underline{x} son los \underline{x}_j que satisfacen $\|\underline{x} - \underline{x}_j\| \leq e_{\underline{x}, (K)}$

Definimos el clasificador de los K vecinos más cercanos como

$$d: \mathbb{R}^p \longrightarrow C$$
$$d(\underline{x}) \longrightarrow \arg \max_j \sum_{\|\underline{x}_i - \underline{x}\| \leq e_{\underline{x}, (K)}} \mathbb{1}_{\{y_i = c_j\}}, \quad \text{donde}$$

2) **Regresión**: en este caso $y_i \in \mathbb{R}$.

La función de regresión es

$$f(\underline{x}) = \frac{1}{K} \sum_{i: \|\underline{x}_i - \underline{x}\| \leq e_{\underline{x}, (K)}} y_i$$

Si \underline{x}_0 es un valor particular, entonces $f(\underline{x}_0)$ es una aproximación de $E[Y | \underline{X} = \underline{x}_0]$

¿Qué es $E[Y | \underline{X} = \underline{x}]$?

Sea (Y, \underline{X}) una tupla de v.a. con fdp conjunta $f_{Y, \underline{X}}(y, \underline{x})$.

Dado $\underline{x} = \underline{x}_0$, queremos aproximar Y por $g(\underline{x})$,
con $g: \mathbb{R}^p \rightarrow \mathbb{R}$.

El costo cuadrático de g es

$$E[(Y - g(\underline{X}))^2] \\ = \int_{\mathbb{R}^p} \int_{\mathbb{R}} (y - g(\underline{x}))^2 f_{Y, \underline{X}}(y, \underline{x}) dy d\underline{x} \quad (1)$$

En la expresión azul, \underline{x} está fija y y es la variable de integración. Cuando \underline{x} está fija entonces $f_{Y, \underline{X}}(y, \underline{x}) = f_{Y | \underline{X} = \underline{x}}(y) f_{\underline{X}}(\underline{x})$.

Recordemos que la fdp condicional de Y dado $\underline{X} = \underline{x}_0$

$$\text{es } f_{Y | \underline{X} = \underline{x}_0}(y) = \frac{f_{Y, \underline{X}}(y, \underline{x})}{f_{\underline{X}}(\underline{x})} \Big|_{\underline{x} = \underline{x}_0}$$

$$= f_{Y, \underline{X}}(y, \underline{x}_0) / f_{\underline{X}}(\underline{x}_0).$$

$f_{Y | \underline{X} = \underline{x}_0}(y)$ es una función solo de y . Así

$$E[(Y - g(\underline{X}))^2] = \int_{\mathbb{R}^p} \int_{\mathbb{R}} (y - g(\underline{x}))^2 f_{Y | \underline{X} = \underline{x}}(y) f_{\underline{X}}(\underline{x}) dy d\underline{x} \\ = \int_{\mathbb{R}^p} \left[\int_{\mathbb{R}} (y - g(\underline{x}))^2 f_{Y | \underline{X} = \underline{x}}(y) dy \right] f_{\underline{X}}(\underline{x}) d\underline{x} \\ = \int_{\mathbb{R}^p} E_{Y | \underline{X} = \underline{x}}[(Y - g(\underline{x}))^2] f_{\underline{X}}(\underline{x}) d\underline{x}$$

$$= E_{\underline{X}} [E_{Y|\underline{X}} [(Y - g(\underline{X}))^2]] \quad (2)$$

La fórmula (2) indica que para minimizar el costo cuadrático de $g(\cdot)$ se puede hacer la minimización condicionando sobre \underline{X} y luego tomando la esperanza con respecto a \underline{X} .

$$\begin{aligned} E_{Y|\underline{X}=\underline{x}_0} [(Y - g(\underline{x}_0))^2] &= E_{Y|\underline{X}=\underline{x}_0} [Y^2 - 2g(\underline{x}_0)Y + g^2(\underline{x}_0)] \\ &= E_{Y|\underline{X}=\underline{x}_0} [Y^2 - 2cY + c^2], \text{ con } c = g(\underline{x}_0). \\ &= -2c E_{Y|\underline{X}=\underline{x}_0} [Y] + c^2. \quad (3) \end{aligned}$$

Para minimizar esta expresión con respecto a c , derivemos con respecto a c e igualamos la derivada a 0:

$$\frac{d}{dc} E_{Y|\underline{X}=\underline{x}_0} [(Y - g(\underline{x}_0))^2] = -2 E_{Y|\underline{X}=\underline{x}_0} [Y] + 2c \quad (4)$$

$$\frac{d}{dc} E_{Y|\underline{X}=\underline{x}_0} [(Y - g(\underline{x}_0))^2] = 0 \Leftrightarrow c = E_{Y|\underline{X}=\underline{x}_0} [Y].$$

$$\text{Así } g(\underline{x}_0) = E_{Y|\underline{X}=\underline{x}_0} [Y] \quad (5)$$

Si se reemplaza (5) en (2) se obtiene la pérdida condicional de g :

$$\begin{aligned} E_{\underline{X}} [E_{Y|\underline{X}} [(Y - E_{Y|\underline{X}} [Y^2]) ^2]] &= \\ &= E_{\underline{X}} [V [Y | \underline{X}]] \end{aligned}$$

Por otro lado el MSE o pérdida cuadrática del estimador $\hat{\theta}$ del parámetro θ es

$$\begin{aligned} \text{MSE}(\hat{\theta}) &= E[(\hat{\theta} - \theta)^2] \\ &= E\left[\left((\hat{\theta} - E[\hat{\theta}]) + (E[\hat{\theta}] - \theta)\right)^2\right] \\ &= E[(\hat{\theta} - E[\hat{\theta}])^2] + 2E[(\hat{\theta} - E[\hat{\theta}])(E[\hat{\theta}] - \theta)] + E[(E[\hat{\theta}] - \theta)^2] \\ &= V[\hat{\theta}] + B^2[\hat{\theta}], \quad B[\hat{\theta}] = E[\hat{\theta}] - \theta \end{aligned}$$

Esto quiere decir que el MSE de $g()$ se puede ver como:

$$\text{MSE}(g) = V[g(\underline{X})] + B^2[g(\underline{X})],$$

$$\text{donde } B[g(\underline{X})] = E[g(\underline{X})] - \gamma$$